

ANALISI GEOSTATISTICA DEI DATI AMBIENTALI – Livello base (T28_25_3_1)

Francesco Pirotti

2025-09-30

Contents

0.1	Riferimenti utili	4
0.2	Obiettivo	4
0.3	Dati di esempio	4
0.4	Cosa facciamo	5
0.5	Giorno 1	5
1	Richiamo concetti statistici fondamentali: varianza, covarianza, correlazione, auto-correlazione	5
1.1	Varianza	5
1.2	Varianza esempio	6
1.3	Varianza esempio (2)	7
1.4	Covarianza	8
1.5	Esempio Covarianza	8
1.6	Covarianza	8
1.7	Covarianza	9
1.8	Covarianza	9
1.9	Covarianza	10
1.10	Correlazione	12
1.11	Autocorrelazione	12
2	Richiamo concetti base su sistemi di riferimento coordinate (CRS), geografiche e proiettate	13
2.1	Cosa sono i dati spaziali?	13
2.2	Modello vettoriale	13
2.3	Modello raster	13
2.4	Modello raster	13
2.5	Sistemi di riferimento	14
2.6	Sistemi di riferimento - geoide	15
2.7	Sistemi di riferimento - ellissoide	15

2.8	Coordinate geografiche	16
2.9	Coordinate geocentriche	17
2.10	Coordinate cartografiche	17
2.11	Coordinate cartografiche	17
2.12	I sistemi di riferimento (CRS)	17
2.13	Un esercizio con R	19
3	Fondamenti statistici dell'analisi spaziale dati e variabili regionalizzate	19
3.1	Variabili regionalizzate	19
3.2	Statistica descrittiva di base	19
4	Metodi deterministici di stima per interpolazione spaziale	19
4.1	Metodi deterministici vs stocastici	19
4.2	Vicino più prossimo (Nearest Neighbour - NN)	20
4.3	Vicino Naturale (Natural Neighbour - NatN)	20
4.4	Inverso pesato sulla distanza (IWD)	21
4.5	Esempio IDW	21
4.6	Esportiamo su raster GeoTIFF per GIS	23
4.7	Esportiamo su raster GeoTIFF per GIS	24
4.8	Esercizio finale giorno 1	24
5	Giorno 2	24
5.1	Giorno 2 - sommario	24
5.2	Dataset Meuse.grid	25
5.3	Conversione tra oggetti per IDW et al.	25
5.4	Terra vs Stars	26
5.5	Stimare il valore in una posizione	26
5.6	Stimare il valore in una posizione - esercizi	26
5.7	IDW con covariate	26
5.8	IDW con covariate	27
5.9	IDW con covariate	28
5.10	Kriging	29
5.10.1	Che cos'è $\varepsilon(s)$?	29
5.11	Stazionarietà e isotropia	30
5.12	Stazionarietà e isotropia	30
5.13	Stazionarietà e isotropia	31
5.14	Stazionarietà	31
5.15	Stazionarietà - segue	31
5.16	Stazionarietà - esempio	31
5.17	Stazionarietà: Approcci pratici	32
5.18	Stazionarietà: Considerazioni importanti	33

5.19	Test di stazionarietà - variogramma	33
5.20	Variogramma	33
5.21	Perchè SEMIvarianza	34
5.22	Semivarianza formula empirica	34
5.23	Semivariogramma - attenzione	35
5.24	Elementi del semivariogramma	35
5.25	Effetto nugget	35
5.26	Semivariogramma - cloud vs. plot	36
5.27	Semivariogramma- esercizio interattivo	36
5.28	Modelli di variogramma	36
5.29	Modelli di variogramma (2)	36
5.30	Semivariogramma - esempi 1	36
5.31	Semivariogramma - esempi 2	36
5.32	Semivariogramma - esempi 3	36
5.33	Semivariogramma - esempi 4	36
5.34	Autocorrelogramma	36
5.35	Stazionarietà - variogramma	36
5.36	Isotropia	41
5.37	Variabili regionalizzate	41
6	Giorno 3	42
6.1	Giorno 3 - sommario	42
6.2	Studio variografico	42
6.3	Studio variografico	43
6.4	Studio variografico	43
6.5	Stimare il modello ed i parametri	44
6.6	Stimare il modello ed i parametri	44
6.7	Anisotropia - stima direzione	45
6.8	Interpolazione kriging	46
6.9	Interpolazione kriging - esercizio	47
6.10	Kriging: tipologie	49
6.10.1	Geostatistica uni-(co)variata	49
7	TECNICHE DI KRIGING - Diversi Kriging	50
7.1	Simple Kriging (SK)	50
7.2	Ordinary Kriging (OK)	50
7.3	Universal Kriging (UK)	51
7.4	Esercizio SK, OK, UK	51
7.5	Co-Kriging (CK)	52
7.6	Come funziona CK:	52

7.7	Differenze chiave rispetto al Kriging ordinario:	52
7.8	Vantaggi del Co-Kriging:	53
7.9	Applicazioni del Co-Kriging:	53
7.10	External drift Kriging (EDK)	53
7.11	Come funziona EDK:	53
7.12	Differenze chiave rispetto al Kriging universale:	53
7.13	Vantaggi dell'EDK:	53
7.14	Regression Kriging (RK)	54
7.15	Come funziona RK:	54
7.16	Differenze chiave RK rispetto ad altri metodi:	54
7.17	Vantaggi di RK:	54
7.18	Applicazioni del RK:	54
7.19	Indicator Kriging (IK)	55
7.20	Alcune criticità	55
7.21	Esercizio finale	55
7.22	Prossimo corso...	55

0.1 Riferimenti utili

CRS - coordinate reference system

<https://r.geocompx.org/spatial-class#crs-intro>

<https://r-spatial.org/book/02-Spaces.html#sec-crs>

meuse dataset

<https://cloud.r-project.org/web/packages/gstat/vignettes/gstat.pdf>

metodi di interpolazione geografica

<https://r-spatial.org/book/12-Interpolation.html>

Applied Spatial Data Analysis with R <https://gis.humboldt.edu/OLM/r/Spatial%20Analysis%20With%20R.pdf>

0.2 Obiettivo

Stimare i valori di una variabile nel dominio dello spazio (eventualmente anche del tempo)

Cosa si intende per variabilità spaziale?

- Lo stesso fenomeno ha valori diversi se misurato in punti diversi
- Le differenze quasi mai sono puramente casuali: esiste una **dipendenza spaziale** (o autocorrelazione)
- I valori dei punti vicini tendono a somigliarsi di più rispetto a punti lontani → questo è ciò che la geostatistica quantifica.

0.3 Dati di esempio

Useremo il dataset “meuse” e le librerie che vedete sotto

Table 1: Dataset *meuse*

x	y	cadmium	copper	lead	zinc	elev	dist	om	ffreq	soil	lime	landuse	dist.r
181072	333611	11.7	85	299	1022	7.909	0.0013580	13.6	1	1	1	Ah	5
181025	333558	8.6	81	277	1141	6.983	0.0122243	14.0	1	1	1	Ah	3
181165	333537	6.5	68	199	640	7.800	0.1030290	13.0	1	1	1	Ah	15
181298	333484	2.6	81	116	257	7.655	0.1900940	8.0	1	2	0	Ga	27
181307	333330	2.8	48	117	269	7.480	0.2770900	8.7	1	2	0	Ah	38

```
library(tidyverse)
library(stats)
library(ggplot2)
library(terra)
library(gstat)
library(kableExtra)
library(sp)
data(meuse)
class(meuse)
```

```
## [1] "data.frame"
```

```
kable(head(meuse, 5), caption = "Dataset *meuse*") %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover"))
```

0.4 Cosa facciamo

Vogliamo un modello per “spiegare” la variabilità e dunque poter stimare (interpolare) al meglio dove non abbiamo informazioni.

Stimare valori di una variabile applicando un modello creato conoscendo valori misurati (e.g. campionamenti). E' ragionevole adottare un criterio spaziale, ovvero usare un criterio di spazio (il valore del punto sarà probabilmente più simile ad una misura vicina che una misura più lontana, a parità di altre condizioni). Da qui la geostatistica.

0.5 Giorno 1

- Richiamo concetti statistici fondamentali: varianza, covarianza, correlazione, autocorrelazione
- Richiamo concetti base su sistemi di riferimento coordinate (CRS), geografiche e proiettate
- Fondamenti statistici dell'analisi spaziale dati e variabili regionalizzate
- Metodi deterministici di stima per interpolazione spaziale (IWD)

1 Richiamo concetti statistici fondamentali: varianza, covarianza, correlazione, autocorrelazione

1.1 Varianza

Vediamo come valutare alcuni momenti di una distribuzione - media e varianza ci danno il primo e secondo momento. Z è la variabile aleatoria, nel caso del dataset MEUSE possiamo scegliere la concentrazione di Zinco.




Figure 1: fonte: Appunti GIS Prof. Alberto Guarnieri - CIRGEO

$$M(Z) = \mu_Z = \mathbb{E}[Z]$$

$$M(Z) = \mu_Z = \frac{1}{n} \sum_{j=1}^n Z_j$$

$$Var(Z) = \sigma_Z^2 = \mathbb{E}[(Z - \mathbb{E}[Z])^2].$$

$$Var(Z) = \sigma_Z^2 = \frac{\sum_{j=1}^n (Z_j - M_Z)^2}{n}$$

Formula più pratica

$$Var(Z) = \sigma_Z^2 = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2$$

$$Var(Z) = \sigma_Z^2 = M(Z^2) - M(Z)^2$$

1.2 Varianza esempio


Calcoliamo la varianza con tre formule diverse:

```

MZ<-mean(meuse$zinc)
VarZ <- var(meuse$zinc)
## media quadratica dei quadrati
MZ2<-mean(meuse$zinc^2)
VarZ <- MZ2 - MZ^2
VarZ <- mean((meuse$zinc-MZ)^2)

plot( meuse$y, meuse$zinc, xlab="Coord Y", ylab="Zinco", pch="+")
abline(a = MZ,0 )
rect(min(meuse$y), MZ-VarZ^0.5, max(meuse$y),
      MZ+VarZ^0.5, col = "#ff000045", border = "#ffffff00")

```



```

# varianza = (dev std)^2


```

1.3 Varianza esempio (2)

```

hist(meuse$zinc)
rug(meuse$zinc)
rect(MZ-VarZ^0.5, 10000,
      MZ+VarZ^0.5, 0, col = "#ff000045", border = "#ffffff00")
abline(v=MZ, col="red", lwd=2)

```



1.4 Covarianza

La **covarianza** tra due variabili casuali Z_1 e Z_2 misura quanto esse tendono a variare insieme. Se positiva variano entrambe nella stessa direzione, se negativa in direzioni opposte.

$$\text{Cov}(Z_1, Z_2) = \mathbb{E}[(Z_1 - \mathbb{E}[Z_1])(Z_2 - \mathbb{E}[Z_2])]$$

1.5 Esempio Covarianza

La covarianza dipende dalle unità di misura delle variabili → non è standardizzata. Per questo si usa spesso la **correlazione**, che normalizza la covarianza tra -1 e 1.

La correlazione = 1 equivale ad una covarianza che ha valore uguale alla varianza.

```
CovZ <- cov(meuse$zinc, meuse$zinc)
```

```
var(meuse$zinc) == CovZ
```


```
## [1] TRUE
```

1.6 Covarianza

Analizziamo un gradiente di temperatura simulato

```
load("oggetti.rda")
plot(lat_seq, temps, type = "l", col = "blue", lwd = 2,
     xlab = "Latitude (°N)", ylab = "Temperature (°C)",
     main = "Gradiente Temperatura: Italia → Danimarca")
points(lat_seq, temps, pch = 16, col = rgb(0,0,1,0.3))
```

Gradiente Temperatura: Italia -> Danimarca



1.7 Covarianza

La covarianza equivale alla varianza se la calcoliamo confrontandola a se stessa, ma se trasliamo di un dato intervallo (“lag”) e la ricalcoliamo, la covarianza non diventa zero, diminuisce gradualmente...

```
cov(temps, temps)
```

```
## [1] 6.150969
```

```
cov(temps[2:200], temps[1:199])
```

```
## [1] 5.122209
```

```
cov(temps[3:200], temps[1:198])
```

```
## [1] 4.972588
```

```
## Provatte con una variabile senza correlazione  
# rand <- runif(200)  
# cov(rand, rand)  
# cov(rand[2:200], rand[1:199])  
# cov(rand[3:200], rand[1:198])
```


Questo è un concetto molto importante da comprendere.

1.8 Covarianza

Più aumentiamo la distanza del lag, come è ragionevole pensare per dati spazialmente correlati, più diminuisce il valore di covarianza (si allontana dal valore della varianza == covarianza).

Se si abbassa per poi rialzarsi, può indicare un pattern ricorrente (provate sostituendo i valori di temps con un valore ciclico come `temps <- sin((1:200)/10)`).

```
nm <- length(temps)
plot(temps[1:200], temps[1:200], pch="x", cex=0.5, xlab="Temperatura", ylab="Temperatura" )
points(temps[1:199], temps[2:200], pch="x", cex=0.5, col="red" )
points(temps[1:198], temps[3:200], pch="x", cex=0.5, col="green" )
```




1.9 Covarianza

Non ci crediamo? Rifacciamolo per un dato casuale con media e varianza uguale a quella del nostro dato:


```
t.rand <- rnorm(nm, mean = MZ, sd = VarZ^0.5)

plot(t.rand[1:(nm-1)], t.rand[2:nm], pch="x", cex=0.5, xlab="km", ylab="Temperatura" )
cc=1
covs.rand<-list("0"=cov(t.rand, t.rand), "1"=cov(t.rand[1:(nm-1)], t.rand[2:nm] ) )

for(lag in seq(6, 36, 10)){
  covs.rand[[as.character(lag)]] <- cov(t.rand[1:(nm-lag)], t.rand[(lag+1):nm])
  points(t.rand[1:(nm-lag)], t.rand[(lag+1):nm], cex=0.5, pch="x", col=cc )
  cc=cc+1
}
```



```
plot(names(covs.rand), unlist(covs.rand), type="b",
      ylab="Covarianza",
      xlab="lag" )
```



1.10 Correlazione

Relazione lineare tra due variabili, cosiddetta di Pearson. Semplicemente normalizza la covarianza per le deviazioni standard delle due variabili moltiplicate tra loro:

$$-1 \leq \rho_{Z1Z2} = \frac{Cov(Z1Z2)}{\sqrt{Var(Z1)} \cdot \sqrt{Var(Z2)}} = \frac{\sum_{i=1}^n (Z1 - \mu_{Z1})(Z2 - \mu_{Z2})}{\sqrt{\sum_{i=1}^n (y_i - \mu_{Z1})^2} \sqrt{\sum_{i=1}^n (y_i - \mu_{Z2})^2}} \leq +1$$

1.11 Autocorrelazione

L'autocorrelazione misura quanto una variabile è correlata con sé stessa quando viene considerato uno spostamento nel dominio dei valori.

In una sola dimensione — sia essa tempo o spazio (ad esempio nel nostro transetto di temperatura SUD → NORD) — questo spostamento viene detto *lag*, traducibile come sfasamento.

L'analisi dell'autocorrelazione si effettua tramite la funzione CCF (Cross-Correlation Function), che nel caso specifico valuta la correlazione della serie con sé stessa a diversi lag.


`acf()` in R ti mostra l'autocorrelazione ai vari lag (sfasamenti).

- Lag = 1 → confronta ogni punto con il successivo.
- Lag più grandi → confrontano punti sempre più distanti lungo il transetto.

```
#ccf(temps, temps, plot = F)
#ccf(temps, temps)

# Autocorrelazione
acf(temps, main = "Autocorrelazione della temperatura")
```

Autocorrelazione della temperatura



2 Richiamo concetti base su sistemi di riferimento coordinate (CRS), geografiche e proiettate

2.1 Cosa sono i dati spaziali?

Rappresentare informazioni associate alla loro posizione nello spazio

Due modelli: il modello vettoriale ed il modello raster.

Ogni valore è georiferito, ovvero associato ad un punto in un sistema di riferimento, quindi delle coordinate.

L'accuratezza può variare a seconda dello strumento usato per la misura.

L'accuratezza dipende dalla scala, che determina la tolleranza agli errori.

2.2 Modello vettoriale

I dati vettoriali hanno tre primitive geometriche di base: punti linee e poligoni. La base è sempre il punto con una coordinate, in 2d o 3d.




Figure 2: By M. W. Toews - Own work, CC BY-SA 4.0

Ci sono decine di formati digitali per i dati vettoriali.

Per un riferimento vedete la pagina [QUL](#).

Ad oggi gli strumenti in ambiente R di riferimento per leggere dati vettoriali è la libreria `sf`.

2.3 Modello raster

Il formato raster è una semplificazione/discretizzazione dello spazio in celle/pixel/ nodi a passo costante, quindi una “griglia” georiferita mediante uno o più punti. Il passo della griglia è spesso identico nelle due direzioni (ma non necessariamente), e ne determina la risoluzione spaziale.

2.4 Modello raster

Può essere 3D (voxel)

Ci sono decine di formati di file che rappresentano dati raster. Per un riferimento vedete la pagina [QUL](#).

Ad oggi la libreria di riferimento per leggere questi dati è la libreria `terra`, e `stars`

Attenzione alla gestione della memoria in quanto i dati raster possono diventare molto pesanti dal punto di vista di spazio di memoria (1000 pixel x 1000 pixel è un raster “piccolo” ma già fornisce 10^6 elementi).





Figure 3: fonte: appunti GIS Prof. Alberto Guarnieri

2.5 Sistemi di riferimento


Sono delle convenzioni - si stabilisce un sistema con una origine ed un orientamento degli assi tra loro perpendicolari - Coordinate planimetriche o polari - Sistemi locali o globali



2.6 Sistemi di riferimento - geoide

Prima di tutto bisogna definire un riferimento fisico - la forma della superficie definita come “interfaccia solida” è “complicata” (è elastica e subisce l’effetto di svariate forze che la deformano)... e neanche stabile nel tempo!


Si prende come convenzione la forma che avrebbe la superficie equipotenziale (livello del mare) se non ci fossero terre emerse - lo si chiama **GEOIDE**. E’ la superficie di riferimento per comprendere dove la gravità spinge l’acqua. NB è in corso con il recente piano di telerilevamento nazionale il calcolo di un nuovo geoide ufficiale nazionale (vedi qui)



2.7 Sistemi di riferimento - ellissoide

Il geoide è fondamentale per comprendere fenomeni legati alle quote, ma molto complesso da trattare. Si semplifica con l’**ellissoide**, una rappresentazione trattabile matematicamente.

Ci sono tanti ellissoidi che sono stati stimati per avvicinarsi il più possibile alla realtà del geoide



$$\frac{X^2 + Y^2}{a^2} + \frac{Z^2}{b^2} = 1$$

a = semiasse maggiore

b = semiasse minore


n_p = normale all'ellissoide in P

P' = proiezione di P sull'ellissoide

2.8 Coordinate geografiche


Latitudine e longitudine, coordinate polari.

superficie ellissoidica



Fonte Slides: Prof. Alberto Guarnieri TESAF|CIRGEO


2.9 Coordinate geocentriche



2.10 Coordinate cartografiche

Coordinate planimetriche, su un piano. Ma la terra non è piatta!

Soluzione: accettiamo deformazioni ma le teniamo sotto controllo (scala, accuratezza, tolleranza)



2.11 Coordinate cartografiche

Si proiettano i punti nella "sfera" su un piano.

2.12 I sistemi di riferimento (CRS)

Vedi documentazione di QGIS QUI

Vedi NOTA PER IL CORRETTO UTILIZZO DEI SISTEMI GEODETICI




Figure 4: Fonte: QGIS documentation

2.13 Un esercizio con R

Le coordinate di Prato della Valle: Lat: 45.398557, Long. 11.876460 trasformate nei vari sistemi. **TEST** - prova a consultare il documento IGM e trasformare la coordinata nel sistema “RDN2008 / Zone 12 (N-E)” e vedere come differisce dal sistema “RDN2008 / Italy zone (N-E)” ... sono uguali?

```
library(sf)
lat<-45.398557
long<-11.876460
# punti in classe SF
pt <- st_sfc(st_point(c(long, lat)), crs = 4326)
# UTM fuso 32
pt_utm <- st_transform(pt, 32632)
#
pt_ecef <- st_transform(pt, 4978)
# le coordinate nei vari sistemi
geographic = sf::st_coordinates(pt)
planimetric = st_coordinates(pt_utm)
geocentric = st_coordinates(pt_ecef)
```

3 Fondamenti statistici dell’analisi spaziale dati e variabili regionalizzate

3.1 Variabili regionalizzate

variabili misurate in punti e correlate spazialmente

- Possono essere trattate come campioni di un fenomeno continuo (non discreto)
- Presentano autocorrelazione spaziale

3.2 Statistica descrittiva di base

Vedi slides iniziali

- Media, mediana, varianza, deviazione standard
- Distribuzione dei dati (istogrammi, boxplot)
- Identificazione di outlier - per il trattamento rigoroso delle osservazioni (non lo trattiamo)
- Differenze tra dati indipendenti e dati spazialmente correlati

4 Metodi deterministici di stima per interpolazione spaziale

4.1 Metodi deterministici vs stocastici

I metodi deterministici non considerano la componente aleatoria (incerta, casuale) dei dati, ma si basano su assunzioni deterministiche per stimare i valori in punti non campionati - ovvero **non considerano la struttura spaziale, nessuna autocorrelazione e non forniscono incertezza**.

Stimano il valore Z^* in un punto dove non abbiamo una misura usando le misure note vicine, ma come?

$$Z^* = F(x, y) = \sum_{i=2}^n w_i Z_i$$


dove il peso del punto 1 dipende dalla distanza h di un i -esimo numero di punti n

4.2 Vicino più prossimo (Nearest Neighbour - NN)

Semplicemente quello più vicino

$$Z_* = Z_i$$

Dove Z_i è il vicino più prossimo e Z_* il punto da interpolare



4.3 Vicino Naturale (Natural Neighbour - NatN)

poligoni di Thiessen danno l'area di influenza.

$$Z_* = Z_i$$

dove il peso è indicato da Sibson

$$Z_i(\mathbf{x}) = \frac{A(\mathbf{x}_i)}{A(\mathbf{x})}$$

dove $A(x)$ è il volume della nuova cella centrata in $\mathbf{x}$ e $A(\mathbf{x}_i)$ è il volume dell'intersezione tra la nuova cella centrata in $\mathbf{x}$ e la vecchia cella centrata in $\mathbf{x}_i$.

- interpolatore esatto: i valori dei dati originali vengono mantenuti nei punti di riferimento.
- crea una superficie liscia priva di discontinuità.




Figure 5: By Markluffel - Own work, CC BY-SA 3.0

- è interamente locale, in quanto si basa su un sottoinsieme minimo di posizioni dei dati che esclude le posizioni che, pur essendo vicine, sono più distanti di un'altra posizione in una direzione simile.
- è adattivo dal punto di vista spaziale e si adatta automaticamente alle variazioni locali della densità dei dati o della disposizione spaziale.
- privo di ipotesi statistiche (puramente deterministico).
- può essere applicato a insiemi di dati molto piccoli, poiché non è basato su dati statistici.
- privo di parametri, quindi semplice

4.4 Inverso pesato sulla distanza (IWD)

$$Z^* = F(x, y) = \sum_{i=2}^n w_i Z_i$$

dove il peso dipende dalla distanza h

$$w_i = \frac{h_i^{-p}}{\sum_{j=i}^n h_j^{-p}}$$

e da una potenza p che va inserita dall'utente e può essere oggetto di ottimizzazione.

4.5 Esempio IDW

```
library(sp)
library(gstat)
data(meuse.grid)
data(meuse)
```




Figure 6: By Hassan Hadji CC-BY-SA Wiki

```
## molto importanti i passaggi sotto
coordinates(meuse) = ~x+y
coordinates(meuse.grid) = ~x+y
gridded(meuse.grid) = TRUE
###
zinc.idw = idw(zinc~1, meuse, meuse.grid)
```


```
## [inverse distance weighted interpolation]
```

```
class(zinc.idw)
```

```
## [1] "SpatialPixelsDataFrame"
## attr(,"package")
## [1] "sp"
```

```
spplot(zinc.idw["var1.pred"], main = "Interpolazione IDW concentrazione Zinco")
```

Interpolazione IDW concentrazione Zinco




4.6 Esportiamo su raster GeoTIFF per GIS

La libreria terra riconosce l'oggetto "sp" - posso aprirlo con qualsiasi software GIS! Nota: non vengono specificati sistemi di riferimento.

```
zinc.idw.terra <- terra::rast(zinc.idw)
plot(zinc.idw.terra, main="Mappa Concentrazione Zinco")
```

Mappa Concentrazione Zinco



```
# terra::writeRaster(zinc.idw.terra, "zincIDW.tif")
```

4.7 Esportiamo su raster GeoTIFF per GIS

Conoscendo l'area, vicino a Maastricht - Paesi Bassi - applichiamo un SR probabile e verifichiamo aprendo in GIS

```
terra::crs(zinc.idw.terra) <- "EPSG:28992"  
# terra::writeRaster(zinc.idw.terra, "zincIDW.tif", overwrite=T)
```



4.8 Esercizio finale giorno 1

Eseguite la procedura sopra per interpolare la variabile “lead” (piombo). Salvate il GeoTIFF con il sistema di riferimento corretto nella cartella condivisa QUI dentro la cartella “giorno1” nominando il file cognome_nome.tif

5 Giorno 2


5.1 Giorno 2 - sommario

- Metodi deterministici di stima per interpolazione spaziale (IWD ed altri) - approfondimenti
- Kriging come interpolatore esatto (onora i punti): che cos'è e a cosa serve, basi teoriche
- Assunzioni su stazionarietà ed isotropia nei processi di kriging
- Variogramma sperimentale e modello di variogramma: range, sill e nugget - introduzione.

5.2 Dataset Meuse.grid

Eseguiamo il codice alla sezione Esempio IDW e vediamo bene cosa accade e come sfruttare la libreria terra e stars per facilitarci la vita. Vediamo che con un oggetto “terra” vengono disegnati vari “livelli” contenuti nell’informazione meuse.grid.

```
plot(meuse.grid)
```



```
## convertiamo il dataset meuse
meuse.grid.terra <- terra::rast(meuse.grid)
# plot(meuse.grid.terra)
# plot(meuse.grid.terra)
```

5.3 Conversione tra oggetti per IDW et al.

Fondamentalmente gli interpolatori sono stimatori/predittori di valori della variabile dipendente in punti geolocalizzati. IDW se usata con formula senza covariate per stimare la concentrazione di zinco in funzione della distanza dai valori noti, ha bisogno solo dei valori con le posizioni (meuse) e di una griglia o di coordinate. Queste devono essere in oggetti di classi Spatial*, sf o stars.

```
library(stars)
library(terra)
library(sf)
library(gstat)
library(sp)
### input IDW: meuse sono i dati (locations) e newdata sono le coordinate dove stimare il valore di
zinc.idw = idw(formula=zinc~1, locations= meuse, newdata=meuse.grid)
## trasformo in oggetto "terra" funziona?
meuse.grid.terra <- terra::rast(meuse.grid)
# zinc.idw.terra = idw(formula=zinc~1, locations= meuse, newdata=meuse.grid.terra)
## trasformo in oggetto "stars" funziona?
```

```
meuse.grid.stars <- stars::st_as_stars(meuse.grid)
zinc.idw.stars = idw(formula=zinc~1, locations= meuse, newdata=meuse.grid.stars)

## trasformo in oggetto "vector" funziona?
meuse.grid.terra.vect <- as.points(meuse.grid.terra) # coordinate
# zinc.idw.punto.vect = idw(formula=zinc~1, locations= meuse, newdata=meuse.grid.terra.vect)
## trasformo in oggetto "sf" funziona?
meuse.grid.sf <- sf::st_as_sf(meuse.grid.terra.vect)
zinc.idw.punto.vect = idw(formula=zinc~1, locations= meuse, newdata=meuse.grid.sf)

## funziona solo con oggetti classe Spatial, sf o stars (vedi manuale)
```

5.4 Terra vs Stars

Libreria *terra* ottima per alcune applicazioni, *stars* per altre. Stars può essere usata come input per interpolatori IDW KRIGING etc... *Terra* consente di usare funzioni utili come *click* (vedi slide successiva)

5.5 Stimare il valore in una posizione

Definiamo una o più coordinate dal grafico fatto con *terra*, e la usiamo come input alla funzione *idw* - NB la funzione *click* usa come input un plot di un oggetto classe raster o vector di *terra*

```
## prendiamo una coordinata dal grafico ,
## la trasformiamo in sf e la usiamo per stimare conc. zinco
## per questo però dobbiamo usare la libreria terra!
message("codice commentato da fare in autonomia in quanto richiede interazione manuale")

## codice commentato da fare in autonomia in quanto richiede interazione manuale

# plot(meuse.grid.terra[[1]])
# p <- click(meuse.grid.terra, n=1, xy=TRUE )
# print(p)
# ## devo trasformare in sf oppure in spatial*
# p_sf <- sf::st_as_sf(p, coords = c("x", "y"), crs = crs(meuse.grid.terra))
# zinc.idw.punto = idw(formula=zinc~1, locations= meuse, newdata=p_sf)
# print(zinc.idw.punto)
```

5.6 Stimare il valore in una posizione - esercizi


Attenzione - solo elementi "terra" vengono correttamente identificati con la funzione *click*

```
bubble(meuse, "zinc")
# p <- click(meuse.grid.terra, n=1, xy=TRUE)
plot(terra::vect(meuse), "zinc")
# p <- click(meuse.grid.terra, n=1, xy=TRUE)
p_sf <- sf::st_as_sf(p, coords = c("x", "y"), crs = crs(meuse.grid.terra))
zinc.idw.punto = idw(formula=zinc~1, locations= meuse, newdata=p_sf)
```

5.7 IDW con covariate

Ma la concentrazione di zinco sembra essere correlata in qualche modo con la distanza dal fiume? Avere una covariata di facile misura può aiutare la stima, non solo con IDW ma anche con Kriging (vediamo dopo il co-kriging). Sembra ci sia una relazione, ma non lineare

```
plot(meuse$dist, meuse$zinc)
```




```
# plot(zinc~dist, meuse)
```

5.8 IDW con covariate

Non è lineare ma possiamo trasformare i valori in log e radice quadrata

```
plot(log(zinc)~sqrt(dist), meuse)
abline(lm(log(zinc)~sqrt(dist), meuse))
cor.zinc.dist <- cor(log(meuse$zinc),sqrt(meuse$dist))
mtext(paste("R=", round(cor.zinc.dist, 3)), side = 3)
```



5.9 IDW con covariate

Siccome questa informazione è implicitamente presente, dato che ho potenzialmente la posizione dei fiumi e dunque la distanza da essi, posso usarla, ma IDW non ha nella sua composizione spazio per un modello di trend per includere covariate, quindi va trattata separatamente.


```
lm_fit <- lm(log(zinc) ~ sqrt(dist), data = meuse)
meuse$resid <- residuals(lm_fit)
## IDW dei residui
idw_res <- idw(resid ~ 1, meuse, meuse.grid)
```

```
## [inverse distance weighted interpolation]
```

```
## stimo dal modello lineare la concentrazione zinco
meuse.grid$trend <- predict(lm_fit, newdata = as.data.frame(meuse.grid))
## aggiungo i residui stimati
meuse.grid$logzinc_idwreg <- meuse.grid$trend + idw_res$var1.pred
meuse.grid$zinc_idwreg <- exp(meuse.grid$logzinc_idwreg)

spplot(meuse.grid["zinc_idwreg"], main = "IDW Zinco con covariata distanza")
```

IDW Zinco con covariata distanza



5.10 Kriging

Metodo di stima/interpolazione stocastico, non-deterministico. E' "esatta" nel senso che onora i punti - ma anche le medie nell'area Bayesiana di maggiore probabilità (zona grigia nella figura)

$$Z(s) = m(s) + \epsilon(s)$$

- $Z(s)$ = valore della variabile al punto s
- $m(s)$ = **trend/mean** (parte "deterministica", modellata da costante, covariate o regressione)
- $\epsilon(s)$ = **componente spaziale**, parte aleatoria

5.10.1 Che cos'è $\epsilon(s)$?

- È il **processo stocastico residuo** dopo aver tolto la media (trend).
- Ha queste proprietà statistiche:

1. $\mathbb{E}[\epsilon(s)] = 0$ (media nulla)
2. La covarianza dipende solo dalla distanza fra punti (stazionarietà di 2° ordine):
 $\text{Cov}(\epsilon(s), \epsilon(s+h)) = C(h)$
3. La sua variabilità è descritta dal **variogramma**:
 $\gamma(h) = \frac{1}{2} \mathbb{E}[(\epsilon(s) - \epsilon(s+h))^2]$

La media $m(s)$ può essere:

- **costante** → kriging ordinario

- **costante nota** → kriging semplice
- **funzione di covariate** → kriging universale / di regressione

Poiché il kriging è **regressione + interpolazione spaziale**, è possibile includere direttamente le covariate nel modello di trend.




Figure 7: Fonte: wikipedia - I quadrati indicano la posizione dei dati. L'interpolazione con kriging, mostrata in rosso, segue le medie degli intervalli credibili a distribuzione normale mostrati in grigio. La curva tratteggiata rappresenta una spline che è liscia, ma si discosta in modo significativo dai valori attesi forniti da quelle medie.

5.11 Stazionarietà e isotropia

L'interpolazione con kriging si basa su alcune assunzioni fondamentali riguardo alla natura dei dati spaziali. Tra queste, le più importanti sono la stazionarietà e l'isotropia.

- attenti: si presuppone un processo stocastico “stazionario”, ovvero:
 - media costante in tutta l'area analizzata
 - la varianza delle differenze dei valori analizzati dipende solo dalla **distanza** tra coppie di punti e non dalla loro posizione

I due presupposti principali affinché il kriging fornisca la migliore previsione lineare imparziale sono quelli della stazionarietà e dell'isotropia, sebbene esistano varie forme e metodi di kriging che consentono di allentare la forma più rigorosa di ciascuno di questi presupposti. Tuttavia, nella realtà, queste condizioni sono spesso violate, rendendo necessario adottare approcci più flessibili.

5.12 Stazionarietà e isotropia

1. Stazionarietà “formale”: le proprietà statistiche (media e varianza) del processo spaziale rimangono costanti **in tutte le località**. La distribuzione di probabilità congiunta non varia nello spazio di studio. Di conseguenza, i parametri (come la media complessiva dei valori, l'intervallo e la soglia del variogramma*) non variano nello spazio di studio. Si presume che lo stesso modello di variogramma* sia valido in tutto lo spazio di studio. Si tratta di un'ipotesi che raramente si verifica nei dati del mondo reale.

2. Stazionarietà “debole”: si ipotizza che la media e la varianza/covarianza siano costanti nella regione di interesse

* Spoiler: il variogramma è un grafico con l’asse delle x che rappresenta la distanza tra due punti e l’asse delle y che rappresenta la varianza delle differenze tra i valori misurati in quei due punti. Solitamente si usa il SEMIvariogramma, ovvero la semivarianza, i.e. metà della media di tutte le differenze tra valori di punti che si trovano entro una certa distanza reciproca.

5.13 Stazionarietà e isotropia

3. Isotropia: l’autocorrelazione spaziale tra le risposte in 2 siti dipende solo dalla distanza e non dalla direzione o dall’orientamento. dipende solo dalla distanza e forse dalla direzione dell’orientamento, non dalla posizione di questi siti nella regione di interesse. siti sono situati nella regione di interesse.
4. Continuità spaziale: l’autocorrelazione spaziale tra le risposte in 2 siti dipende solo dalla distanza e forse dalla direzione dell’orientamento tra i due punti non dalla posizione di questi siti nella regione di interesse.

5.14 Stazionarietà

La caratteristica di stazionarietà è fondamentale per molte tecniche geostatistiche

Stazionarietà di primo ordine: stazionarietà della media, ovvero un campione in due aree diverse della regione di studio hanno media uguale. Media quindi può essere costante (processo stazionario) o funzione dello spazio (trend deterministico) esempio la temperatura che cambia con la latitudine .

Stazionarietà di secondo ordine: stazionarietà della varianza, ovvero un campione in due aree diverse della regione di studio hanno varianza uguale.

5.15 Stazionarietà - segue



Quasi sempre rappresenta una semplificazione della realtà.

La dimostrazione della stazionarietà in pratica è complesso per le seguenti ragioni:

1. **Dati limitati**: I dati geostatistici sono tipicamente sparsi e irregolarmente distribuiti, rendendo difficile valutare le proprietà statistiche sull’intera area di studio.
2. **Eterogeneità spaziale**: La maggior parte dei fenomeni naturali presenta una certa variabilità spaziale.
3. **Dipendenza dalla scala**: I pattern spaziali possono cambiare con la scala, complicando la valutazione della stazionarietà.

5.16 Stazionarietà - esempio

Simulazione da un dataset completo temperatura, usando due transetti, vediamo effettivamente la difficoltà nel soddisfare queste condizioni:



5.17 Stazionarietà: Approcci pratici

Metodi per valutare il grado di stazionarietà:

- **Analisi esplorativa dei dati (EDA):**
 - Visualizzare i dati utilizzando istogrammi, scatter plot e mappe per identificare potenziali trend o pattern.
 - Calcolare statistiche descrittive (media, varianza) per diversi sottoinsiemi dei dati per verificare la consistenza.
- **Analisi del variogramma:**

- Esaminare il variogramma per evidenziare la stazionarietà (ad esempio, raggiungimento di un plateau, comportamento isotropo).
- Considerare l'adattamento di diversi modelli di variogramma per valutare la loro aderenza.

5.18 Stazionarietà: Considerazioni importanti

- **La stazionarietà è spesso un'approssimazione:** In pratica, spesso si assume una stazionarietà approssimativa per applicare i metodi geostatistici.
- **Stazionarietà locale:** Può essere ragionevole assumere la stazionarietà all'interno di sottoregioni più piccole.
- **Metodi non stazionari:** Se la stazionarietà è chiaramente violata, considerare l'utilizzo di metodi geostatistici non stazionari (e.g. Universal Kriging o Regression Kriging) o altre tecniche di analisi spaziale.

Ricorda: L'obiettivo non è dimostrare la stazionarietà senza ombra di dubbio, ma valutare la sua plausibilità e prendere decisioni informate sull'adeguatezza dei metodi geostatistici

5.19 Test di stazionarietà - variogramma

Insomma... i miei dati 2D soddisfano il presupposto di stazionarietà o no? O almeno quanto sono lontani da una perfetta stazionarietà?

NB - La stazionarietà è una decisione, non un'ipotesi (cit. M. Pyrcz); pertanto non può essere testata. I dati possono dimostrare che non è una supposizione appropriata.

La valutazione della stazionarietà dipende dalla scala. La scelta della scala deve basarsi sul problema specifico.

Per indagare/valutare la stazionarietà dei dati spaziali, in pratica la cosa migliore è usare un **variogramma o un autocorrelogramma**: - nel primo caso è un grafico che mostra come cambia il valore la covarianza a diversi lag.

5.20 Variogramma

Per ogni coppia di punti a una determinata distanza, si calcola la metà della differenza al quadrato dei loro valori. Questa quantità è chiamata **semivarianza**. Il variogramma mette nell'asse X la distanza e nell'asse Y la semivarianza calcolata in funzione della distanza (h).

Il kriging utilizza il semivariogramma, o meglio un modello matematico del semivariogramma, per calcolare le stime della superficie ai nodi della griglia. Queste stime di kriging sono le migliori stime lineari oggettive della superficie nelle posizioni specificate, a condizione che la superficie sia stazionaria e che sia stata determinata la forma corretta del semivariogramma.

$$\gamma(h) = \frac{1}{2} \text{Var}[Z(s) - Z(s+h)]$$

- $Z(s)$ = valore della variabile casuale nel punto sss.
- h = vettore di spostamento (distanza e direzione).
- La varianza delle differenze cresce con h : punti vicini tendono a somigliarsi (piccola $\gamma(h)$), punti lontani sono indipendenti (plateau).


5.21 Perchè SEMIvarianza

- Serve a mantenere la relazione con la **varianza**:
quando $h \rightarrow \infty$, la semivarianza tende alla **varianza della variabile** (non al doppio!)
- In pratica il fattore $\frac{1}{2}$ è una convenzione che garantisce che il semivariogramma sia coerente con le proprietà statistiche del processo.

5.22 Semivarianza formula empirica

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} \left(Z(s_i) - Z(s_i + h) \right)^2$$

```
lzn.vgm = variogram(log(zinc)~1, meuse)
#plot(lzn.vgm)
# prova a aggiungere argomento cloud=TRUE alla funzione variogram!
lzn.fit = fit.variogram(lzn.vgm, model = vgm(1, "Sph", 900, 1))
plot(lzn.vgm, lzn.fit)
```



- $Z(s_i)$ = valore osservato della variabile al punto s_i .
- $Z(s_i + h)$ = valore osservato al punto separato da distanza (o lag o intervallo di distanza solitamente nel semivario) h .
- $N(h)$ = numero di coppie di punti che distano circa h .
- La differenza al quadrato $(Z(s_i) - Z(s_i + h))^2$ misura la dissimilarità tra i due punti
- La somma fa la media di tutte le dissimilarità per le coppie a distanza h .

5.23 Semivariogramma - attenzione

Ogni punto della nuvola rappresenta una coppia di punti nel set di dati, quindi il numero di punti nella nuvola aumenterà rapidamente all'aumentare del numero di punti nel set di dati. Per n punti nel set di dati, la nuvola di semivariogramma/covarianza visualizzerà

$$\frac{n * (n - 1)}{2}$$


punti. Per questo motivo, non è consigliabile utilizzare set di dati con più di qualche migliaio di punti.

5.24 Elementi del semivariogramma

- **Nugget:** Il valore iniziale del variogramma, indica la variabilità a brevissima distanza. Un nugget elevato suggerisce una componente casuale significativa.
- **Sill:** Il valore massimo a cui tende il variogramma, rappresenta la variabilità totale.
- **Portata:** La distanza alla quale il variogramma raggiunge il sill, indica la distanza oltre la quale i valori sono considerati indipendenti.

Il variogramma si dice delimitato se raggiunge un massimo tetto (sill) di varianza - vuol dire che c'è stazionarietà.

Se il variogramma non è delimitato (non raggiunge un massimo) non c'è (trend).



5.25 Effetto nugget

E' la varianza indipendente dall'autocorrelazione spaziale. Ad esempio dovuta agli errori di misura.




Figure 8: Fonte: Dr. Gaufeng Cao - University of Colorado Boulder

5.26 Semivariogramma - cloud vs. plot

5.27 Semivariogramma- esercizio interattivo

```
lzn.vgm = variogram(log(zinc)-1, meuse, cloud=TRUE)

plot(plot(lzn.vgm, identify = TRUE), meuse)
# plot(plot(lzn.vgm, digitize = TRUE), meuse)
```

5.28 Modelli di variogramma

5.29 Modelli di variogramma (2)

5.30 Semivariogramma - esempi 1

5.31 Semivariogramma - esempi 2

5.32 Semivariogramma - esempi 3

5.33 Semivariogramma - esempi 4

5.34 Autocorrelogramma

Nel secondo caso è un grafico che mostra l'autocorrelazione dei valori dei dati a diversi lag (spaziali o temporali).

Si vuole studiare l'associazione tra le osservazioni della variabile analizzata in funzione di distanza e direzione. Le funzioni di covarianza, il correlogramma e il variogramma / il semivariogramma sono tutte funzioni che caratterizzano numericamente la forza di tali associazioni.

5.35 Stazionarietà - variogramma

Il variogramma può aiutare a decidere se la variabile dipendente è stazionaria o meno.

Forma coerente: La forma complessiva del variogramma (ad esempio, sferica, esponenziale) deve rimanere coerente in diverse parti dell'area di studio.

model	syntax	$\gamma(h)$	h range
Nugget	1 Nug(0)	0 1	$h = 0$ $h > 0$
Spherical	1 Sph(a)	$\frac{3h}{2a} - \frac{1}{2}(\frac{h}{a})^3$ 1	$0 \leq h \leq a$ $h > a$
Exponential	1 Exp(a)	$1 - \exp(\frac{-h}{a})$	$h \geq 0$
Linear	1 Lin(0)	h	$h \geq 0$
Linear-with-sill ¹	1 Lin(a)	$\frac{h}{a}$ 1	$0 \leq h \leq a$ $h > a$
Circular	1 Cir(a)	$\frac{2h}{\pi a} \sqrt{1 - (\frac{h}{a})^2} + \frac{2}{\pi} \arcsin \frac{h}{a}$ 1	$0 \leq h \leq a$ $h > a$
Pentaspherical	1 Pen(a)	$\frac{15h}{8a} - \frac{5}{4}(\frac{h}{a})^3 + \frac{3}{8}(\frac{h}{a})^5$ 1	$0 \leq h \leq a$ $h > a$
Gaussian	1 Gau(a)	$\gamma(h) = 1 - \exp(-(\frac{h}{a})^2)$	$h \geq 0$
Bessel ²	1 Bes(a)	$1 - \frac{h}{a} K_1(\frac{h}{a})$	$h \geq 0$
Logarithmic	1 Log(a)	0 $\log(h + a)$	$h = 0$ $h > 0$
Power	1 Pow(a)	h^a	$h \geq 0, 0 < a \leq 2$
Periodic	1 Per(a)	$1 - \cos(\frac{2\pi h}{a})$	$h \geq 0$

Figure 9: Courtesy of: GSTAT manual - <https://www.gstat.org/gstat.pdf>





Figure 10: Courtesy of E.J. Pebesma - <https://www.gstat.org/gstat.pdf>

Quadratic shape near origin:




Interpretation:

- highly continuous (extremely smooth) spatial attribute variability
- spatial attribute is differentiable
- typical variables: elevation, temperature, ...

Figure 11: Fonte: Dr. Gaufeng Cao - University of Colorado Boulder

Linear shape near origin:




Interpretation:

- continuous variability (not extremely smooth) of spatial attribute
- attribute is not differentiable
- typical variables: ore grades, ...

Figure 12: Fonte: Dr. Gaufeng Cao - University of Colorado Boulder

Discontinuous near origin:




Interpretation:

- highly irregular (quasi-random) spatial variability at small scales
- typical variables: precipitation, ...

Figure 13: Fonte: Dr. Gaufeng Cao - University of Colorado Boulder

Oscillating (around sill):



Interpretation:

- periodic variability of spatial attribute yields sinusoidal semivariogram
- semivariogram shape possibly due to limited sampling
- need to provide physical evidence for periodicity
- frequently encountered in time series

Figure 14: Fonte: Dr. Gaufeng Cao - University of Colorado Boulder

Nessuna tendenza sistematica: Il variogramma non deve presentare tendenze chiare verso l'alto o verso il basso all'aumentare della distanza.


Nessuna dipendenza dalla posizione: Il variogramma non deve variare in modo significativo a seconda della posizione delle coppie di punti all'interno dell'area di studio. Test di stazionarietà - variogramma (3)

Vedi portale interattivo Geospatial App

5.36 Isotropia

Direzionalità - si può testare fornendo un valore di *alpha* al variogramma.

```
lzn.dir = variogram(log(zinc)~1, meuse, alpha = c(0, 45, 90, 135))
lzn.dir.fit = vgm(.59, "Sph", 1200, .05, anis = c(45, .4))
plot(lzn.dir, lzn.dir.fit, as.table = TRUE)
```



5.37 Variabili regionalizzate

Sono grandezze il cui valore dipende dalla localizzazione ovvero dal vettore delle [X Y] di coordinate spaziali.

La teoria delle variabili regionalizzate non utilizza l'autocorrelazione, ma una proprietà correlata chiamata semivarianza per esprimere il grado di relazione tra i punti di una superficie.

La semivarianza è semplicemente la metà della varianza delle differenze tra tutti i possibili punti distanziati da una distanza costante.

La semivarianza a una distanza $d = 0$ dovrebbe essere pari a zero, perché non ci sono differenze tra punti che vengono confrontati con se stessi. Tuttavia, man mano che i punti vengono confrontati con punti sempre più distanti, la semivarianza aumenta. A una certa distanza, chiamata intervallo,

la semivarianza diventerà approssimativamente uguale alla varianza della superficie stessa. Si tratta della massima distanza su cui il valore di un punto della superficie è correlato al valore di un altro punto.

L'intervallo definisce il massimo vicinato su cui selezionare i punti di controllo per stimare un nodo della griglia, per sfruttare la correlazione statistica tra le osservazioni. Nel caso in cui il nodo della griglia e le osservazioni siano distanziate in modo tale che tutte le distanze superino l'intervallo, il kriging produce la stessa stima della statistica classica, ovvero la media.

6 Giorno 3

6.1 Giorno 3 - sommario


- Variogramma sperimentale e modello di variogramma: range, sill e nugget - esercizi
- Studio variografico di una variabile georeferenziata
 - verifica stazionarietà e isotropia
- Predizione e varianza di kriging
- Esercizi con Kriging

6.2 Studio variografico

Condizione di isotropia - verifica.

Esercizio - stima con una variabile completamente casuale

```
#meuse$rand <- runif(nrow(meuse))
plot(variogram(log(zinc) ~ 1, meuse, alpha = c(0, 45, 90, 135)))
```




6.3 Studio variografico

Scala e densità di campioni (vedi app online per simulare campionamenti)

La distanza di **cutoff**, che è la distanza massima fino alla quale le coppie di punti vengono considerate, e il **width** è l'ampiezza dell'intervallo di distanza all'interno del quale le coppie di punti vengono mediate nei bin


```
plot(variogram(log(zinc) ~ 1, meuse, cutoff = 2000, width = 50))
```



6.4 Studio variografico

Intervalli personalizzati

```
v<-variogram(log(zinc) ~ 1, meuse, boundaries = c(0, 50, 100, seq(250, 1500, 250)))  
plot(v)
```



6.5 Stimare il modello ed i parametri

Gstat utilizza il metodo dei minimi quadrati per stimare i parametri di un modello che riteniamo possa essere adatto. Se i dati non sono coerenti con il modello, potrebbe dare una non-soluzione (singular fit) e non trovare i parametri del modello.

Esercizio - fornite voi a mano un sill, nugget e range (vedi documentazione vgm e Variogramma)

```
# show.vgms()
# NB come mai fornisce un singular fit?
v.fit <- fit.variogram(v, vgm(1, "Sph", 10, 1))
```


```
## Warning in fit.variogram(v, vgm(1, "Sph", 10, 1)): singular model in variogram
## fit
```

```
# ?vgm
```


6.6 Stimare il modello ed i parametri

Se c'è anisotropia (l'autocorrelazione dipende dalla direzione oltre che dalla distanza reciproca) possiamo integrarlo nel modello imponendola

```
v.dir <- variogram(log(zinc) ~ 1, meuse, alpha = (0:3) * 45)
v.anis <- vgm(0.6, "Sph", 1600, 0.05, anis = c(45, 0.3))
plot(v.dir, v.anis)
```




```
v.fit <- fit.variogram(v.dir, v.anis)
plot(v.dir, v.fit)
```



6.7 Anisotropia - stima direzione

```
plot(variogram(log(zinc) ~ 1, meuse, map = TRUE, cutoff = 1000, width = 100))
```




6.8 Interpolazione kriging

Una volta trovato il modello adatto possiamo usarlo per l'interpolatore usando la componente stocastica - ad esempio usiamo il modello che tiene in considerazione la leggera anisotropia dei nostri dati.

```
v.dir <- variogram(log(zinc) ~ 1, meuse, alpha = (0:3) * 45)
v.anis <- vgm(0.6, "Sph", 1600, 0.05, anis = c(45, 0.3))
v.fit <- fit.variogram(v.dir, v.anis)
lz.sk <- krige(log(zinc) ~ 1, meuse, meuse.grid, v.fit, beta = 5.9)
```

```
## [using simple kriging]
```


```
plot(lz.sk)
```



6.9 Interpolazione kriging - esercizio

Provate ad applicare la stessa cosa ad una variabile differente ed ad utilizzare TERRA per creare i due plot.


```
v.dir2 <- variogram(log(copper) ~ 1, meuse, alpha = (0:3) * 45)
v.anis <- vgm(0.6, "Sph", 1600, 0.05, anis = c(45, 0.3))
v.fit <- fit.variogram(v.dir2, v.anis)
plot(v.dir2, v.fit)
```




```
lz.sk.cu <- krige(log(copper) ~ 1, meuse, meuse.grid, v.fit, beta = 5.9)
```

```
## [using simple kriging]
```

```
plot(terra::rast(lz.sk.cu), main="Rame" )
```



```
plot(terra::rast(lz.sk), main="Zinco" )
```




6.10 Kriging: tipologie

6.10.1 Geostatistica uni-(co)variata

Una variabile sola considerata o con multivariata (co-kriging)

- **Simple K** - si presuppone una media costante nota nell'area di lavoro
- **Ordinary K** - si presuppone una media costante ma ignota
- **Universal K** - si presuppone una media ignota non costante ma con un trend lineare



7 TECNICHE DI KRIGING - Diversi Kriging

7.1 Simple Kriging (SK)

Presuppone che la media della variabile regionalizzata sia nota. Richiede una conoscenza accurata della media. Si applica nel caso di funzioni aleatorie stazionarie con media dei residui costante e nota. Necessita di un elevato numero di dati misurati.

```

vg <- variogram(log(zinc)~1, meuse)
fit <- fit.variogram(vg, vgm("Sph"))

sk <- krige(log(zinc)~1, meuse, meuse.grid, model=fit,
            beta=5.5) # conosciamo la media e la forniamo

```

[using simple kriging]

7.2 Ordinary Kriging (OK)

Assume che la media della variabile regionalizzata sia sconosciuta e costante. Ampiamente utilizzato per la maggior parte delle applicazioni **dove non c'è trend**. Fornisce stime e i relativi errori. Si applica nel caso di funzioni aleatorie stazionarie, ossia nel caso in cui la media dei residui sia costante in tutto il dominio di studio (stazionarietà!)

```

vg <- variogram(log(zinc)~1, meuse)
fit <- fit.variogram(vg, vgm("Sph"))

sk <- krige(log(zinc)~1, meuse, meuse.grid, model=fit) # niente media, viene stimata con metodo de

```

[using ordinary kriging]

7.3 Universal Kriging (UK)

Incorpora una superficie di tendenza (polinomiale) per modellare variazioni su larga scala. Utile quando c'è una chiara tendenza nei dati, come nel nostro caso studio.

Si applica nel caso di funzioni aleatorie non stazionarie intrinseche, ossia nel caso in cui la media dei residui non è costante e la legge di autocorrelazione presenta un trend.

La funzione aleatoria $Z(x)$ può essere considerata in ogni punto x del dominio come la sovrapposizione di due componenti:

$$Z(s) = m(s) + \epsilon(s)$$

- $Z(s)$ = valore della variabile al punto s
- $m(s)$ = **trend/mean** (parte “deterministica”, modellata da costante, covariate o regressione)
- $\epsilon(s)$ = **componente spaziale**, parte aleatoria

Se la componente residua $\epsilon(s)$ è una funzione stazionaria e non è correlata al trend allora è possibile applicare la procedura di Kriging al residuo e quindi effettuare Universal Kriging (UK).

7.4 Esercizio SK, OK, UK

Riassumendo; provate a cambiare alcuni parametri e visualizzare il risultato

```
mean(log(meuse$zinc))
```

```
## [1] 5.885776
```

```
lz.sk <- krige(log(zinc) ~ 1, meuse, meuse.grid, v.fit, beta = 5.9)
```

```
## [using simple kriging]
```

```
# spplot(lz.sk)
```

```
lz.ok <- krige(log(zinc) ~ 1, meuse, meuse.grid, v.fit)
```

```
## [using ordinary kriging]
```

```
# spplot(lz.ok)
```

```
f <- log(zinc) ~ sqrt(dist)
```


```
vt <- variogram(f, meuse)
```

```
vt.fit <- fit.variogram(vt, vgm(1, "Exp", 300, 1))
```

```
lz.uk <- krige(log(zinc) ~ sqrt(dist), meuse, meuse.grid, vt.fit)
```

```
## [using universal kriging]
```

```
spplot(lz.uk)
```



7.5 Co-Kriging (CK)

Il **Co-kriging** è un'estensione del kriging ordinario che incorpora variabili aggiuntive, note come variabili secondarie o ausiliarie, per migliorare l'accuratezza della previsione della variabile primaria di interesse.

```
# Creo oggetto gstat con due variabili
g <- gstat(NULL, "zinc", log(zinc)~1, meuse)
g <- gstat(g, "cadmium", log(cadmium)~1, meuse)

# Variogrammi e cross-variogramma
vg <- variogram(g)

# Fit LMC con un modello sferico (va adattato manualmente)
model <- vgm(psill=1, model="Sph", range=900, nugget=0.05)
fit <- fit.lmc(vg, g, model)
```

7.6 Come funziona CK:

- **Variabili multiple:** Considera più variabili contemporaneamente. **Correlazione incrociata:** Utilizza la correlazione incrociata tra le variabili primarie e secondarie.
- **Previsione migliorata:** Incorporando le informazioni provenienti da variabili correlate, il co-kriging può spesso fornire previsioni più accurate rispetto al kriging ordinario.

7.7 Differenze chiave rispetto al Kriging ordinario:

Dati: Il kriging ordinario utilizza una sola variabile, mentre il co-kriging utilizza più variabili.

Complessità del modello: Il co-kriging comporta la modellazione delle correlazioni incrociate tra le variabili, rendendolo più complesso del kriging ordinario.

Accuratezza della previsione: Il co-kriging spesso porta a un miglioramento dell'accuratezza della previsione grazie alle informazioni aggiuntive fornite dalle variabili secondarie.

7.8 Vantaggi del Co-Kriging:

- **Miglioramento dell'accuratezza:** Come già detto, può migliorare significativamente l'accuratezza della previsione.
- **Uso efficiente dei dati:** Sfrutta le informazioni provenienti da più variabili, sfruttando al massimo i dati disponibili.
- **Gestire i dati mancanti:** può essere utilizzato per stimare i valori mancanti in una variabile sulla base dei valori di altre variabili.

7.9 Applicazioni del Co-Kriging:

- **Scienze ambientali:** Previsione delle proprietà del suolo, dei livelli di inquinamento atmosferico, ecc. **Idrologia:** Stima dei livelli delle acque sotterranee, delle precipitazioni, ecc. **Geostatistica:** Previsione dei gradi dei minerali, delle riserve minerarie, ecc.

In sostanza, il co-kriging è uno strumento prezioso quando si hanno più variabili correlate e si vuole migliorare l'accuratezza delle proprie previsioni.

7.10 External drift Kriging (EDK)

L'EDK (External Drift Kriging) è una variante dell'Universal Kriging in cui la componente di tendenza o deriva è determinata da variabili esterne anziché dalle sole coordinate spaziali.

```
edk <- krige(log(zinc)~dist, meuse, meuse.grid, model=fit)
```

7.11 Come funziona EDK:

- **Variabili esterne:** si tratta di variabili ausiliarie che influenzano la variabile dipendente. Possono essere qualsiasi cosa, dall'altitudine all'uso del suolo, dal tipo di terreno a qualsiasi altro fattore rilevante.
- Un modello di regressione viene utilizzato per modellare la relazione tra la variabile dipendente e le variabili esterne.
- I residui di questo modello di regressione rappresentano la componente spazialmente correlata dei dati. **Kriging:** Il Kriging ordinario viene quindi applicato a questi residui per interpolarli.
- La previsione finale in una località non campionata è la somma del valore previsto dal modello di regressione e del residuo previsto dal kriging.

7.12 Differenze chiave rispetto al Kriging universale:

- **Definizione della deriva:** Il kriging universale utilizza funzioni polinomiali delle coordinate spaziali per modellare la deriva, mentre l'EDK utilizza variabili esterne.
- **Flessibilità:** EDK offre una maggiore flessibilità in quanto può incorporare vari tipi di variabili esterne, migliorando potenzialmente l'accuratezza della previsione.

7.13 Vantaggi dell'EDK:

- **Migliore accuratezza:** Incorporando variabili esterne rilevanti, EDK può spesso fornire previsioni più accurate rispetto a Universal Kriging.
- **Migliore comprensione:** L'EDK aiuta a comprendere l'influenza dei fattori esterni sulla variabile di interesse.
- **Versatilità:** Può essere applicato a un'ampia gamma di dati e problemi spaziali.

In sostanza, l'External Drift Kriging è un potente strumento di previsione spaziale quando esiste una chiara relazione tra la variabile di interesse e altri fattori esterni.

7.14 Regression Kriging (RK)

Il **Regression Kriging** è una tecnica di interpolazione spaziale che combina i punti di forza della regressione e del kriging. È essenzialmente un metodo ibrido.

```
lm_fit <- lm(log(zinc)~dist, data=meuse@data)
meuse$resid <- residuals(lm_fit)

vg_res <- variogram(resid~1, meuse)
fit_res <- fit.variogram(vg_res, vgm("Sph"))

rk <- krige(resid~1, meuse, meuse.grid, model=fit_res)
rk$pred <- rk$var1.pred + predict(lm_fit, meuse.grid@data)
```

7.15 Come funziona RK:

1. Un modello di regressione viene costruito per spiegare la variazione della variabile target utilizzando variabili ausiliarie (covariate).
2. I residui del modello di regressione rappresentano la parte non spiegata della variazione.
3. I residui vengono interpolati con tecniche di kriging (come il Kriging ordinario) per catturare l'autocorrelazione spaziale.
4. La previsione finale è la somma del valore previsto dal modello di regressione e del residuo previsto dal kriging.

7.16 Differenze chiave RK rispetto ad altri metodi:

- **Combina regressione e kriging:** Questo approccio ibrido sfrutta i punti di forza di entrambi i metodi.
- **Incorpora variabili ausiliarie:** Il kriging di regressione utilizza esplicitamente variabili ausiliarie per migliorare l'accuratezza della previsione.
- Il modello di regressione cattura le tendenze su larga scala, mentre il kriging gestisce l'autocorrelazione spaziale su piccola scala.

7.17 Vantaggi di RK:

- **Migliore accuratezza:** Spesso fornisce previsioni più accurate rispetto al semplice kriging o alla sola regressione.
- **Flessibilità:** Può adattarsi a vari tipi di modelli di regressione e tecniche di kriging.
- **Migliore comprensione:** Aiuta a capire l'influenza delle variabili ausiliarie sulla variabile target.

7.18 Applicazioni del RK:

- **Scienze ambientali:** Previsione dell'inquinamento atmosferico, delle proprietà del suolo, ecc.
- **Idrologia:** Stima dei livelli delle acque sotterranee, delle precipitazioni, ecc. **Agricoltura:** Previsione della resa dei raccolti, dell'umidità del suolo, ecc.

In sostanza, il Kriging di regressione è uno strumento potente quando esistono tendenze o modelli significativi nei dati che possono essere spiegati da variabili ausiliarie e quando esiste anche un'autocorrelazione spaziale nei residui.

7.19 Indicator Kriging (IK)

Tratta i dati come categorici (ad esempio, sopra o sotto una soglia). Utilizzato per la mappatura probabilistica e la valutazione del rischio.

Si ottiene trasformando una variabile continua in un indicatore (0/1), oppure riducendo una variabile categorica a variabile binaria. Un esempio è l'indicatore che vale 1 se lo zinco è **inferiore a 500 ppm** e 0 altrimenti:

```
meuse$ind <- ifelse(meuse$zinc > 1000, 1, 0)

vg_ind <- variogram(ind~1, meuse)
fit_ind <- fit.variogram(vg_ind, vgm("Sph"))

ik <- krige(ind~1, meuse, meuse.grid, model=fit_ind)

## oppure (da bivand et al. )
# Definizione della formula indicatore
ind.f <- I(zinc < 500) ~ 1
# Stima del variogramma
ind.fit <- fit.variogram(variogram(ind.f, meuse), vgm(1, "Sph", 800, 1))
# Kriging per indicatori
ind.kr <- krige(ind.f, meuse, meuse.grid, model = ind.fit)
```

7.20 Alcune criticità

I risultati possono risultare carenti quando:

- La geostatistica viene spesso applicata con pochi dati a disposizione.
- Raramente viene indicato il modello di stima e di interpolazione utilizzato.
- Spesso non vengono indicati i punti utilizzati per l'interpolazione e/o i valori che la variabile assume in tali punti, né il dominio di studio.
- A volte vengono utilizzate condizioni al contorno nell'area (punti fittizi) che non rispecchiano dati reali misurati.
- Raramente vengono applicati più modelli di stima allo stesso set di dati ed effettuato il confronto fra le varianze di stima.
- Quando vengono utilizzati modelli statistici (kriging), non viene riportata la determinazione del variogramma sperimentale e del variogramma modello utilizzato, né viene prodotta la mappa delle incertezze.

non limitarsi solo a fornire delle “mappe”, ma indicare tutte le valutazioni che le hanno prodotte oltre all'incertezza dei risultati.

7.21 Esercizio finale

Esegui un'interpolazione con IDW ed una usando il kriging

7.22 Prossimo corso...

- applicazioni dei vari kriging su dataset differente e più complessi
- co-variogrammi e co-kriging per appaiare più covariate
- metodi di validazioni rigorose
- ...